

UNIVERSIDADE TECNOLÓGICA FEDERAL DO PARANÁ

PEDRO HENRIQUE FERREIRA VINCHI

**O USO DE MACHINE LEARNING PARA PREVISIBILIDADE DO VALOR DE
AÇÕES DA EMPRESA 3M**

CORNÉLIO PROCÓPIO

2025

PEDRO HENRIQUE FERREIRA VINCHI

**O USO DE MACHINE LEARNING PARA PREVISIBILIDADE DO VALOR DE
AÇÕES DA EMPRESA 3M**

The use of machine learning for predicting the stock value of company 3M

Trabalho de Conclusão de Curso de Graduação
apresentado como requisito para obtenção do
título de Bacharel em Engenharia de Software
do Curso de Bacharelado em Engenharia de
Software da Universidade Tecnológica Federal
do Paraná.

Orientador(a): Prof. Dr. Rodrigo Henrique
Cunha Palácios

CORNÉLIO PROCÓPIO

2025



[4.0 Internacional](https://creativecommons.org/licenses/by/4.0/)

Esta licença permite compartilhamento, remixe, adaptação e criação a partir do trabalho, mesmo para fins comerciais, desde que sejam atribuídos créditos ao(s) autor(es). Conteúdos elaborados por terceiros, citados e referenciados nesta obra não são cobertos pela licença.

PEDRO HENRIQUE FERREIRA VINCHI

**TÍTULO DO TRABALHO: SUBTÍTULO (SE HOUVER) PRECEDIDO DE DOIS
PONTOS**

Trabalho de Conclusão de Curso de Graduação
apresentado como requisito para obtenção do
título de Bacharel em Engenharia de Software
do Curso de Bacharelado em Engenharia de
Software da Universidade Tecnológica Federal
do Paraná.

Data de aprovação: dia / mês por extenso / ano

Nome completo e por extenso do Membro 1 (de acordo com o Currículo Lattes)
Titulação (Especialização, Mestrado, Doutorado)
Nome completo e por extenso da instituição a qual possui vínculo

Nome completo e por extenso do Membro 2 (de acordo com o Currículo Lattes)
Titulação (Especialização, Mestrado, Doutorado)
Nome completo e por extenso da instituição a qual possui vínculo

Nome completo e por extenso do Membro 3 (de acordo com o Currículo Lattes)
Título (Titulação (Especialização, Mestrado, Doutorado)
Nome completo e por extenso da instituição a qual possui vínculo

CORNÉLIO PROCÓPIO

2025

Dedico este trabalho à minha família, por
estarem ao meu lado nos bons e maus
momentos, por sempre acreditarem em mim
independente da situação. Vocês são minha
base, meu porto seguro.

AGRADECIMENTOS

Agradeço ao meu orientador Prof. Dr. Rodrigo Henrique Cunha Palácios, por me guiar pelo meu caminho rumo à conclusão do meu curso.

Agradeço à minha terapeuta Rosely Bacelar, sem você esse sonho não seria possível. Obrigado por estar ao meu lado nos momentos mais difíceis e me ajudar a superar meus desafios. Nunca esquecerei tudo o que você fez por mim.

Agradeço ao corpo docente, por todos os conteúdos apresentados em sala de aula, e também por todos os ensinamentos que levarei para a vida.

Agradeço aos meus amigos que fizeram parte dessa trajetória, tornando o caminho mais leve e agradável.

E agradecimento especial a toda à minha família.

RESUMO

A previsibilidade do valor de ações no mercado financeiro representa um desafio constante, considerando a complexidade e a diversidade de fatores econômicos, políticos e sociais que influenciam os preços dos ativos. Métodos tradicionais de análise, embora ainda relevantes, muitas vezes não conseguem capturar adequadamente as interações não lineares e os padrões temporais complexos presentes nos dados financeiros. Diante disso, este trabalho propõe e avalia a eficácia de um modelo de Machine Learning baseado em Redes Neurais Recorrentes (RNN), com a arquitetura Long Short-Term Memory (LSTM), para prever com maior precisão o valor das ações da empresa 3M. A solução foi implementada com dados históricos de fechamento das ações, utilizando técnicas de regularização como Early Stopping e Dropout para melhorar o desempenho do modelo e evitar overfitting. Os resultados obtidos foram promissores, com o modelo alcançando um erro médio quadrático (R^2) superior a 70% nos cenários de teste, demonstrando o potencial do aprendizado profundo como ferramenta de análise e previsão no mercado financeiro. Assim, a principal contribuição deste estudo é oferecer uma abordagem que pode auxiliar investidores e analistas na tomada de decisões mais fundamentadas, contribuindo para o aprimoramento de estratégias de investimento e gestão de risco.

Palavras-chave: redes neurais recorrentes; lstm; previsão de ações; aprendizado profundo.

ABSTRACT

The predictability of stock prices in the financial market represents a constant challenge, considering the complexity and diversity of economic, political, and social factors that influence asset prices. Traditional methods of analysis, although still relevant, often fail to adequately capture the non-linear interactions and complex temporal patterns present in financial data. In light of this, this work proposes and evaluates the effectiveness of a Machine Learning model based on Recurrent Neural Networks (RNN), with a Long Short-Term Memory (LSTM) architecture, to more accurately predict the stock value of the 3M company. The solution was implemented with historical stock closing data, using regularization techniques such as Early Stopping and Dropout to improve the model's performance and prevent overfitting. The results obtained were promising, with the model achieving a mean squared error (R^2) greater than 70% in the test scenarios, demonstrating the potential of deep learning as a tool for analysis and forecasting in the financial market. Thus, the main contribution of this study is to offer an approach that can assist investors and analysts in making more informed decisions, contributing to the improvement of investment and risk management strategies.

Keywords: recurrent neural networks; lstm; stock forecasting; deep learning.

LISTA DE ALGORITMOS

Algoritmo 1 – Importação de Bibliotecas	25
Algoritmo 2 – Função <code>convert_to_float</code>	25
Algoritmo 3 – Função <code>MinMaxScaler</code>	26
Algoritmo 4 – Criação da Estrutura do Modelo	26
Algoritmo 5 – Construção do Modelo	27
Algoritmo 6 – Compilação e Treinamento do Modelo	27
Algoritmo 7 – Testando Modelo e Avaliando as Métricas	28
Algoritmo 8 – Visualizando os Resultados	28

LISTA DE FIGURAS

Figura 1 – Perceptron (P)	16
Figura 2 – Recorrent Neural Network (RNN)	18
Figura 3 – Long/Short Term Memory (LSTM)	18
Figura 4 – Gated Recorrent Unit (GRU)	21
Figura 5 – Ilustração Modelo LSTM	27
Figura 6 – Predição do Valor da Ação 3M - Cenário 2 (R^2: 0.78, MAPE: 11.35%)	30
Figura 7 – Predição do Valor da Ação 3M - Cenário 1 (R^2: 0.77, MAPE: 11.63%)	30
Figura 8 – Predição do Valor da Ação 3M - Cenário 3 (R^2: 0.76, MAPE: 11.41%)	31
Figura 9 – Predição do Valor da Ação 3M - Cenário 4 (R^2: 0.77, MAPE: 11.40%)	31
Figura 10 – Tabela Treino	42
Figura 11 – Tabela Teste	44

LISTA DE TABELAS

Tabela 1 – Sumário das Variáveis e Métricas de Desempenho por Cenário.	29
--	-----------

LISTA DE ABREVIATURAS E SIGLAS

AI	Artificial Intelligence
AM	Aprendizado de Máquina
ML	Machine Learning
RNN	Recurrent Neural Network
LSTM	Long Short Term Memory
CNN	Convolutional Neural Network
AE	Auto-Encoders
GAN	Generative Adversarial Network
RSI	Relative Strength Index
MAPE	Mean Absolute Percentage Error
SVM	Support Vector Machine
MSE	Mean Square Error
GPU	Graphics Processing Unit

SUMÁRIO

1	INTRODUÇÃO	12
1.1	OBJETIVOS	14
1.1.1	Objetivo Geral	14
1.1.2	Objetivos Específicos	14
1.2	ORGANIZAÇÃO DO TRABALHO	14
2	REFERENCIAL TEÓRICO	15
2.1	Machine Learning	15
2.2	Fundamentos Econômicos	19
2.3	Trabalhos Relacionados	20
3	METODOLOGIA	23
3.1	ABORDAGEM DA PESQUISA	23
3.2	AMOSTRA	23
3.3	INSTRUMENTOS E TECNOLOGIAS	23
3.4	PROCEDIMENTO METODOLÓGICO	24
3.4.1	Importação e preparação dos dados	24
3.4.2	Criação da estrutura dos dados de entrada	26
3.4.3	Construção do modelo LSTM	26
3.4.4	Compilação e treinamento do modelo	26
3.5	ANÁLISE DE DADOS	27
3.5.1	Teste e Avaliação do modelo	27
3.5.2	Visualização dos resultados	28
4	RESULTADOS E DISCUSSÃO	29
4.1	Análise de Desempenho dos Cenários	29
4.2	Discussão dos Resultados	32
5	CONSIDERAÇÕES FINAIS	34
	REFERÊNCIAS	36
	APÊNDICES	40
	APÊNDICE A – TABELA TREINO	42
	APÊNDICE B – TABELA TESTE	44

1 INTRODUÇÃO

O termo *Machine Learning* aparece na literatura na década de 1950 por meio do matemático Arthur Samuel, que introduziu o conceito de aprendizado de máquinas (AM) em relação ao jogo de damas (Samuel, 1959). Desde então, houve um crescimento exponencial no uso deste conceito nas diversas áreas do conhecimento, tais como ciências humanas, exatas e biológicas (Haefner *et al.*, 2021; Rizelioğlu, 2025; Balakrishna; Srinivasulu, 2024).

Uma das áreas em que o ML pode ser amplamente empregado é o mercado financeiro, para prever tendências de mercado (Muhammad *et al.*, 2024), fraudes financeiras (Potter, 2024), otimização de investimentos (Avella, 2024) e para proporcionar análises mais precisas e eficientes (Gao *et al.*, 2025). Apesar disso, um dos maiores desafios enfrentado nesse campo é como prever o valor das ações no mercado financeiro (Vijh *et al.*, 2020). Esse desafio se dá pela complexidade inerente ao comportamento dos preços, que é influenciado por uma ampla gama de variáveis econômicas, políticas, sociais e até mesmo psicológicas (Kumar *et al.*, 2022).

Com o avanço das tecnologias de AM, novas possibilidades para a criação de modelos preditivos surgiram, permitindo a análise e a identificação de padrões complexos em grandes volumes de dados financeiros. Estes modelos, quando bem implementados, podem oferecer uma maior previsibilidade do valor das ações, o que pode ser utilizado para aprimorar decisões de investimento e estratégias de gestão de risco (Khan, 2019). Essa evolução tecnológica tem permitido uma maior eficiência na análise e interpretação de dados financeiros.

A previsão dos preços de ações era feita, tradicionalmente, com base em métodos de análise técnica e fundamentalista, que, apesar de úteis, muitas vezes não conseguiam capturar a complexidade das interações entre as diversas variáveis que afetam o comportamento dos ativos. A análise fundamentalista, por exemplo, concentra-se em fatores internos às empresas, como balanços patrimoniais, receitas e lucros, enquanto a análise técnica se baseia no estudo de movimentos passados dos preços e volumes de negociação (Murphy, 1999). Contudo, essas abordagens, isoladamente, podem ser insuficientes para prever mudanças abruptas de preços ou eventos inesperados que impactam o mercado.

A natureza multifatorial e volátil do mercado financeiro faz com que a previsão de preços de ações seja um problema extremamente complexo. Isso porque, as variações de preços são influenciadas por múltiplas variáveis que interagem entre si de forma não linear, tornando o desenvolvimento de modelos preditivos precisos uma tarefa desafiadora. Estudos clássicos, como o de Granger e Newbold (1977), demonstram que modelos estatísticos como a regressão linear podem fornecer previsões aceitáveis em determinados horizontes temporais. Esses modelos baseiam-se na premissa que os preços passados das ações contêm informações relevantes que podem ser utilizadas para prever o comportamento futuro dos preços. Essa abordagem, conhecida como análise de séries temporais, tem sido amplamente utilizada na literatura para prever o comportamento de variáveis econômicas e financeiras (Zheng *et al.*, 2024).

A eficácia da análise de séries temporais foi reforçada pelo trabalho seminal de Fama (Fama, 1970), que introduziu a hipótese dos mercados eficientes. Segundo essa teoria, os pre-

ços das ações refletem todas as informações disponíveis no mercado, de modo que seria impossível prever os preços futuros com base em informações passadas. No entanto, estudos posteriores questionaram essa hipótese, especialmente em mercados que não são perfeitamente eficientes, nos quais é possível identificar padrões em séries temporais que podem ser explorados para gerar previsões de preços. Nesse contexto, o uso de modelos mais complexos, como as redes neurais Long Short-Term Memory (LSTM), tem se mostrado uma abordagem promissora, uma vez que esses modelos são capazes de capturar relações não lineares e dependências temporais nos dados (Zheng *et al.*, 2024).

O uso dos conceitos de redes neurais artificiais, com ênfase em redes neurais recorrentes (RNN) e LSTM, justifica-se, pois as LSTM são particularmente adequadas para a análise de séries temporais longas, uma vez que conseguem reter informações por períodos mais longos e evitam o problema de desvanecimento do gradiente, comum em outras arquiteturas de redes neurais (Vijh *et al.*, 2020). Além disso, técnicas adicionais relacionadas a séries temporais financeiras, pré-processamento de dados, seleção de variáveis de entrada e métricas de avaliação aplicadas a modelos de aprendizado de máquina podem aumentar a acurácia do modelo. De acordo com a literatura, a combinação de LSTM com indicadores técnicos, como médias móveis, índice de força relativa (RSI) e bandas de Bollinger, pode aumentar ainda mais a precisão das previsões (Sherstinsky, 2018).

Portanto, a capacidade de prever os preços das ações, mesmo que com certo grau de incerteza, tem grande relevância prática no contexto do mercado financeiro (Nascimento; Santos; Ferreira, 2022). Investidores, gestores de fundos e analistas financeiros podem utilizar essas previsões para melhorar suas estratégias de investimento e gestão de risco. Adicionalmente, investidores iniciantes podem se beneficiar dessas previsões ao tomar decisões mais embasadas sobre onde alocar seus recursos. As previsões geradas por modelos LSTM podem, por exemplo, indicar momentos mais propícios para a compra ou venda de ações, o que pode ajudar a maximizar os retornos e minimizar as perdas, razões pelas quais se justifica o presente estudo (Kim; Won, 2018).

Este trabalho tem como objetivo contribuir para o desenvolvimento de modelos de Machine Learning mais precisos e eficazes na previsão do valor das ações no mercado financeiro. Além disso, o trabalho visa: coletar e realizar o pré-processamento dos dados históricos da empresa 3M; implementar um modelo LSTM para aprender os padrões temporais presentes nos dados; treinar e executar o modelo LSTM utilizando os dados históricos pré-processados; testar e avaliar o desempenho preditivo do modelo por meio de métricas de erro como MAPE e o Coeficiente de Determinação (R^2); e, por fim, analisar criticamente os resultados obtidos e as limitações do modelo.

Para isso, realizou-se a aplicação de um modelo LSTM para a previsão de preços das ações da empresa 3M, utilizando dados históricos. A 3M, fundada em 1902, é uma empresa multinacional americana que atua em diversas áreas, desde produtos para saúde e segurança até soluções para indústria e tecnologia, destacando-se por sua forte cultura de pesquisa e desenvolvimento em ciência e tecnologia. O processo de desenvolvimento do modelo envol-

veu várias etapas. Inicialmente, foram coletados e pré-processados os dados, o que incluiu a normalização dos valores e o tratamento de dados ausentes. Em seguida, o modelo LSTM foi implementado e treinado com os dados históricos, de modo a aprender os padrões temporais presentes nos preços das ações. Após o treinamento, o modelo foi testado e avaliado utilizando métricas de erro como o MAPE e o R^2 , que indicam quão próximas as previsões estão dos valores reais. Por fim, os resultados foram analisados criticamente e as limitações do modelo foram discutidas.

Finalmente, a utilização de modelos LSTM, embora promissora, não está isenta de limitações, pois fatores como a qualidade dos dados, a escolha das variáveis de entrada e a própria volatilidade do mercado podem afetar o desempenho do modelo. Contudo, o estudo apresentou uma ferramenta que pode oferecer previsões úteis e aplicáveis no contexto prático do mercado financeiro.

1.1 OBJETIVOS

1.1.1 Objetivo Geral

Desenvolver e avaliar um modelo de Machine Learning baseado em LSTM para melhorar a precisão e eficácia na previsão do valor das ações no mercado financeiro, utilizando dados históricos da empresa 3M.

1.1.2 Objetivos Específicos

1. Realizar a coleta e o pré-processamento dos dados históricos da empresa, garantindo a preparação adequada para o treinamento do modelo.
2. Implementar um modelo de Redes Neurais Recorrentes do tipo LSTM, com foco na captura de padrões temporais presentes nos dados históricos de ações.
3. Treinar e executar o modelo LSTM utilizando os dados históricos pré-processados.
4. Testar e avaliar o desempenho do modelo preditivo utilizando métricas de erro, como o MAPE e o R^2 .
5. Analisar criticamente os resultados obtidos, destacando as limitações do modelo e sugerindo possíveis melhorias para estudos futuros.

1.2 ORGANIZAÇÃO DO TRABALHO

Este trabalho está estruturado em seis capítulos. Sendo eles, 1 Introdução, 2 Referencial Teórico, 3 Metodologia, 4 Resultados e 5 Considerações Finais, além das Referências Bibliográficas e apêndices A,B, consecutivamente.

2 REFERENCIAL TEÓRICO

O presente capítulo apresentou uma revisão da literatura acerca dos principais conceitos e avanços relacionados ao tema de estudo. Está estruturado em três subtópicos: 2.1 Machine Learning, 2.2 Fundamentos Econômicos e 2.3 Trabalhos Relacionados.

Inicialmente em 2.1 Machine Learning, realizou-se uma contextualização histórica da computação, com ênfase no desenvolvimento do AM como subcampo da IA. A evolução deste campo é analisada desde seus fundamentos matemáticos e computacionais, passando pela criação de redes neurais artificiais e seus desdobramentos, até os modelos mais avançados de redes neurais profundas, como as LSTM.

Em seguida, o subtópico 2.2 Fundamentos Econômicos, contemplou uma discussão sobre os mercados financeiros, com destaque para o mercado de capitais, no qual a previsibilidade dos preços das ações constitui um desafio central para investidores e pesquisadores. Foram apresentados conceitos teóricos sobre a regressão linear como método estatístico tradicional de previsão, bem como suas limitações em contextos de dados complexos e dinâmicos. Destacou-se a aplicação de arquiteturas LSTM como uma abordagem avançada para modelagem e previsão de séries temporais no mercado financeiro, evidenciando sua eficácia na captura de padrões relevantes e na melhoria da precisão das estimativas.

Na sequência, o subtópico 2.3 Trabalhos Relacionados, destacou estudos da literatura que realizaram pesquisas semelhantes com foco no uso de ML para previsibilidade de valores de ações, além de evidenciar a relevância e crescimento deste campo de estudo nos últimos anos.

Por fim, este capítulo forneceu os fundamentos teóricos básicos para a compreensão dos aspectos técnicos e econômicos que embasam a proposta deste estudo, estabelecendo um elo entre os conceitos de AM e os desafios do mercado financeiro.

2.1 Machine Learning

A computação, enquanto campo de estudo, começou a se desenvolver na primeira metade do século XX, com a criação das primeiras máquinas de computação. Paralelamente, desenvolveu-se o conceito de Machine Learning, fundamentado por avanços em IA, estatística e matemática. O termo ML, é um subcampo da IA que confere aos computadores a capacidade de aprender sem serem explicitamente programados.

Por volta das décadas de 1940 e 1950, os fundamentos matemáticos e computacionais foram essenciais para a compreensão do processamento de informação. Claude Shannon, em 1948, publicou o artigo *A Mathematical Theory of Communication*, uma teoria que se tornou um marco nesse campo, pois definiu conceitos fundamentais para algoritmos de aprendizagem, como a codificação de dados e a eficiência de transmissão (Shannon, 1948).


Contudo, foi na década de 1950 que o conceito de IA começou a ganhar forma com o surgimento dos primeiros modelos de aprendizagem. Nesse período, o matemático e cientista

da computação Alan Turing introduziu a ideia de máquinas que poderiam aprender com dados. Em seu artigo publicado em 1950, *Computing Machinery and Intelligence*, o autor questionou a capacidade de pensamento de uma máquina e propôs um teste similar a um “jogo de imitação”, que foi posteriormente denominado Teste de Turing. O Teste de Turing foi um dos primeiros trabalhos a propor critérios para a avaliação de inteligência em máquinas (Turing, 2004).

John McCarthy, um dos pioneiros do campo, cunhou o termo IA durante a Conferência de Dartmouth em 1956. Este evento impulsionou discussões sobre a possibilidade de criar máquinas que pudessem aprender e raciocinar, introduzindo conceitos como o de redes neurais (McCarthy *et al.*, 2006). O projeto de pesquisa apresentado na conferência de Dartmouth proporcionou um impulso tanto à IA quanto às Redes Neurais, estimulando a pesquisa na área de processamento neural.

Nos anos seguintes, o neurobiologista Frank Rosenblatt desenvolveu uma pesquisa na qual observou o funcionamento do olho de uma mosca ao tentar fugir. Tal observação resultou no desenvolvimento de uma rede neural simples inspirada no funcionamento de neurônios biológicos, denominada Perceptron, demonstrado na Figura 1. O modelo foi construído em hardware e é considerado a mais antiga rede neural, cujos princípios ainda são estudados (Rosenblatt, 2021). No entanto, as limitações dos modelos iniciais, como o Perceptron, geraram desilusão. Em seu livro *Perceptrons* (1969), Marvin Minsky e Seymour Papert demonstraram que redes neurais simples eram incapazes de resolver problemas não lineares, levando ao declínio do interesse no campo. Apesar de suas limitações, o Perceptron marcou o início das redes neurais artificiais (Minsky; Papert, 2017).

Figura 1 – Perceptron (P)



Fonte: Adaptado de The Asimov Institute.

Na década de 1980, após um período de estagnação, houve um reavivamento no campo de estudo. Em 1985, o Instituto Americano de Física iniciou reuniões anuais sobre Redes Neu-

rais para Computação, o que resultou em novos avanços e na primeira Conferência Internacional sobre Redes Neurais do Institute of Electrical and Electronics Engineers (IEEE), em 1987. Com a introdução do algoritmo de retropropagação de erros (*backpropagation*), foi possível treinar redes neurais mais complexas, superando muitas das limitações anteriores (Rumelhart; Hinton; Williams, 1986).

A década de 1990 foi marcada pelo aprendizado de máquina baseado em dados. Pesquisadores exploravam algoritmos capazes de aprender e realizar tarefas específicas sem instruções explícitas. A crescente disponibilidade de dados online ofereceu um terreno fértil para aplicar esses algoritmos. Os métodos *Support Vector Machine*(SVM), introduzidos por Vapnik e colaboradores, revolucionaram a classificação de dados, destacando-se pela capacidade de lidar com problemas de alta dimensionalidade (Cortes; Vapnik, 1995). A disponibilidade de *Big Data* e o aumento da capacidade computacional permitiram o treinamento de algoritmos mais sofisticados, marcando uma transição para abordagens baseadas em dados (Halevy; Norvig; Pereira, 2009).


Com a expansão do *Big Data*, entre os anos 2000 e 2010, as redes neurais profundas (*Deep Learning*) começaram a dominar tarefas complexas, como visão computacional e processamento de linguagem natural. Trabalhos como *ImageNet Classification with Deep Convolutional Neural Networks* impulsionaram a pesquisa na área (Krizhevsky; Sutskever; Hinton, 2012).

Atualmente, o ML está presente em diversos subcampos da IA, como no processamento de linguagem natural, nas redes neurais e no *Deep Learning* (Lecun *et al.*, 1998). O subcampo das Redes Neurais apresenta diversas arquiteturas, tais como RNNs, segundo Figura 2, LSTMs, redes neurais convolucionais (CNN), autoencoders (AE) e redes adversariais generativas (GAN), entre outras. Cada arquitetura possui um objetivo e uma finalidade, adequando-se de forma mais eficiente às tarefas a que se propõe.

Neste estudo, foram utilizadas as RNNs, que são uma classe de redes neurais projetada para lidar com dados sequenciais, como séries temporais e texto. Diferentemente das redes neurais tradicionais, que assumem que as entradas são independentes umas das outras, as RNNs têm a capacidade de manter uma memória interna, permitindo que informações de entradas anteriores influenciem a saída atual. Essa característica torna as RNNs particularmente adequadas para tarefas em que a ordem dos dados é crucial, como na tradução de idiomas, no reconhecimento de fala e na previsão de séries temporais (Rumelhart; Hinton; Williams, 1986).


Entretanto, as RNNs possuem problemas crônicos, como o desvanecimento e a explosão do gradiente. Esses problemas ocorrem quando os gradientes de uma rede neural se tornam muito pequenos (desvanecimento) ou muito grandes (explosão) durante o treinamento, o que dificulta o aprendizado de dependências de longo prazo. Como resultado, as RNNs tradicionais podem ter dificuldades em capturar informações relevantes de eventos que ocorreram muito antes na sequência de dados (Hochreiter; Schmidhuber, 1997).

Para superar essas limitações, foram introduzidas as redes de LSTM, uma arquitetura de RNN desenvolvida por Sepp Hochreiter e Jürgen Schmidhuber em 1997. As LSTMs, como

Figura 2 – Recurrent Neural Network (RNN)

Fonte: Adaptado de The Asimov Institute.

visito na Figura 3, são projetadas para aprender dependências de longo prazo, utilizando uma estrutura de "célula de memória" que permite que informações sejam armazenadas e recuperadas ao longo do tempo. Essa célula é controlada por três portões (ou gates) principais: o portão de entrada, o portão de saída e o portão de esquecimento. Esses portões determinam quais informações devem ser adicionadas à célula, quais devem ser mantidas e quais devem ser descartadas (Hochreiter; Schmidhuber, 1997).

Figura 3 – Long/Short Term Memory (LSTM)

Fonte: Adaptado de The Asimov Institute.

A arquitetura das LSTMs permite que elas sejam muito mais eficazes do que as RNNs tradicionais em tarefas que envolvem sequências longas e complexas. Elas têm sido amplamente utilizadas em diversas aplicações, incluindo previsão de séries temporais, processamento de linguagem natural, reconhecimento de fala e análise de sentimentos (Hua *et al.*, 2019).

2.2 Fundamentos Econômicos

O mercado financeiro é um sistema essencial que facilita a troca de ativos financeiros, como ações, títulos e derivativos, entre diversos participantes, incluindo indivíduos, empresas e governos (Ross; Westerfield; Jaffe, 2005). Esse ambiente dinâmico desempenha um papel crucial na economia, permitindo a alocação eficiente de recursos, garantindo liquidez e contribuindo para a formação de preços (Brealey *et al.*, 2012).

Os mercados financeiros são geralmente divididos em duas categorias principais: os mercados de capitais, onde ocorrem transações de ações e títulos de longo prazo, e os mercados monetários, que se concentram em instrumentos de dívida de curto prazo (Mishkin; Eakins, 2018). O mercado de capitais, em particular, desempenha um papel vital na mobilização de recursos para investimentos de longo prazo e no financiamento de projetos que impulsionam o crescimento econômico.

No mercado de capitais, as ações representam uma fração do capital social de uma empresa. Quando uma empresa decide abrir seu capital, ela emite ações para o público, permitindo que investidores adquiram uma parte da empresa e, assim, se tornem acionistas. Esses acionistas têm o direito de participar dos lucros da empresa, geralmente na forma de dividendos, e de influenciar decisões corporativas por meio de votos em assembleias (Graham; Dodd, 2008). Além disso, o preço das ações é determinado pela oferta e demanda no mercado, refletindo a percepção dos investidores sobre o valor futuro da empresa e suas perspectivas de crescimento.

Dentro do conceito econômico de mercado de capitais, a previsibilidade dos valores das ações é um conceito fundamental para investidores que buscam maximizar seus retornos e minimizar riscos (Fama; French, 1992). Dada a complexidade do mercado, onde os preços das ações são influenciados por uma grande quantidade de fatores, a capacidade de prever esses preços torna-se um desafio significativo. Nesse cenário, a utilização de métodos estatísticos, como a regressão linear, pode oferecer uma abordagem estruturada para entender e prever o comportamento dos preços das ações (Hull, 2017).

A regressão linear é uma técnica estatística que busca identificar a relação entre uma variável dependente — neste caso, o preço das ações — e sua própria série histórica (Fama; French, 2015). Ao focar exclusivamente nos dados passados dos preços das ações, essa abordagem permite a identificação de padrões e tendências que podem ser utilizados para prever valores futuros. Por meio da aplicação da regressão linear, é possível criar um modelo que estima como as variações nos preços históricos influenciam os preços futuros, proporcionando uma base quantitativa para as previsões.

Essa metodologia é particularmente útil para investidores que desejam fundamentar suas decisões com base em análises históricas, buscando assim maior precisão nas estimativas dos preços das ações (Fama; French, 2015). Uma vez que o modelo de regressão é estabelecido, ele pode ser utilizado para projetar o preço futuro das ações.

Embora a regressão linear seja uma abordagem estatística simples e com resultados aceitáveis, ela é limitada a capturar apenas relações lineares. Arquiteturas LSTM, por outro lado, permitem que o modelo aprenda de forma eficiente com longas e curtas sequências de dados, armazenando informações relevantes ao longo do tempo e esquecendo aquelas que não contribuem para a previsão futura. De forma prática, a LSTM pode lembrar padrões ou eventos passados que tiveram uma influência significativa no comportamento dos preços das ações e, ao mesmo tempo, consegue ignorar ruídos ou flutuações irrelevantes, fazendo com que o modelo crie padrões mais robustos para as previsões. Sendo assim, modelos que utilizam LSTM para prever o valor de ações no mercado financeiro apresentam maior acurácia quando comparados a modelos tradicionais de predição (Lindemann *et al.*, 2021).

2.3 Trabalhos Relacionados

A aplicação de redes neurais, especialmente as do tipo LSTM, tem demonstrado grande potencial na previsão do mercado de ações. Pesquisadores como Moghar e Hamiche (2020) utilizaram dados do Google para validar a eficácia das LSTMs, alcançando resultados promissores e até desenvolvendo uma aplicação web para implementação em tempo real. De forma complementar, Mehtab, Sen e Dutta (2021) propuseram uma abordagem híbrida que combina LSTMs com outras técnicas de machine learning, mostrando que a integração de múltiplos modelos pode aumentar significativamente a precisão das previsões de preços de ações.


Em busca de maior otimização, Song *et al.* (2024) introduziram um modelo que une LSTMs com redes Bayesianas (BO-LSTM). Essa combinação se mostrou eficaz na melhoria do desempenho dos modelos, representando um avanço notável na aplicação de *deep learning* para projeções financeiras. Esses estudos internacionais ressaltam uma tendência clara: modelos complexos e híbridos estão se tornando o padrão para obter previsões mais acuradas no volátil mercado financeiro.

No cenário brasileiro, pesquisadores têm adaptado essas tecnologias para as particularidades do mercado local. Carrijo (2023) focou sua análise no setor bancário, utilizando LSTMs para prever os preços das ações dos maiores bancos do país. Seu estudo revelou a complexa relação entre os índices da bolsa e o desempenho das ações bancárias. Paralelamente, FANTIN (2023) comparou as redes LSTM com as tradicionais *Multi Layer Perceptron* (MLP), concluindo que as LSTMs são superiores na captura de padrões temporais em ativos negociados na B3.

A exploração de modelos alternativos e híbridos também tem ganhado força. Estudos como os de Zaheer *et al.* (2023) e Zulqarnain *et al.* (2020) integraram múltiplas fontes de dados e combinaram CNNs com redes recorrentes. Essas abordagens multimodais permitem capturar tanto padrões espaciais quanto temporais nos dados financeiros, superando os modelos

mais simples. Alternativas às LSTMs, como as *Gated Recurrent Unit* (GRU), como observado na Figura 4, também foram investigadas por (Shen *et al.*, 2018), mostrando-se eficazes e computacionalmente menos complexas.

Figura 4 – Gated Recurrent Unit (GRU)
Gated Recurrent Unit (GRU)



Fonte: Adaptado de The Asimov Institute.

Além da previsão de preços, o ML tem sido amplamente aplicado em finanças quantitativas. Revisões sistemáticas da literatura, como as conduzidas por Rundo *et al.* (2019) e Sahu, Mokhade e Bokde (2023), confirmam que algoritmos de *deep learning*, especialmente as LSTMs, superam consistentemente métodos estatísticos tradicionais. Essas técnicas são a base para o desenvolvimento de estratégias de *trading* algorítmico e otimização de portfólios, como detalhado por Jansen (2020) e Pricope (2021), que exploram desde a extração de sinais do mercado até o uso de aprendizado por reforço para criar agentes de *trading* autônomos.

Apesar dos avanços, a literatura existente apresenta limitações significativas. Muitos estudos não tratam adequadamente o risco de *overfitting*, falham em realizar uma validação robusta dos modelos fora do período de amostragem e, crucialmente, ignoram custos de transação e outras variáveis práticas que afetam a viabilidade real das estratégias propostas. Além disso, poucos trabalhos consideram o impacto de mudanças abruptas de regime no mercado, como crises financeiras, que podem invalidar os modelos.

Diante dessas lacunas, o presente trabalho busca oferecer contribuições específicas. Ao contrário de análises mais genéricas, esta pesquisa se aprofunda no estudo de um único ativo, a empresa 3M, permitindo uma análise mais detalhada de suas particularidades. Utilizando um extenso conjunto de dados históricos de 2013 a 2024, o estudo cobre diferentes ciclos econômicos, o que favorece a generalização dos resultados. Adicionalmente, são implementadas técnicas rigorosas de validação para garantir a confiabilidade do modelo.

Em suma, a literatura demonstra que as redes neurais LSTM consolidaram-se como uma ferramenta poderosa e em constante evolução para a previsão de mercados financeiros, superando métodos tradicionais. No Brasil, há um esforço crescente para adaptar essas técnicas às condições locais. Este estudo se insere nesse contexto ao fornecer uma análise aprofundada e metodologicamente rigorosa sobre um ativo específico, visando contribuir tanto para o conhecimento teórico quanto para as aplicações práticas da área.

3 METODOLOGIA

Este capítulo está estruturado em 5 subtópicos: Abordagem da Pesquisa, Amostra, Instrumentos e Tecnologias, Procedimento Metodológico e Análise de Dados. Descreve de forma detalhada a metodologia empregada no desenvolvimento do presente estudo, incluindo as etapas, as estratégias e ferramentas utilizadas para a coleta, tratamento, análise e modelagem dos dados. O delineamento metodológico foi estruturado com base em uma abordagem quantitativa e explicativa, visando identificar padrões e variáveis relevantes à previsibilidade de ações futuras no mercado financeiro

3.1 ABORDAGEM DA PESQUISA

Trata-se de um estudo quantitativo do tipo explicativo, tendo em vista que o objetivo principal da pesquisa é identificar padrões ou variáveis relevantes na previsibilidade de ações futuras.

3.2 AMOSTRA

A amostra do presente estudo compreendeu os dados históricos do valor das ações da empresa 3M, referentes aos dias de operação entre 01/08/2013 até 30/09/2024, publicados no site Yahoo Finance.

A 3M, uma das líderes globais em inovação e tecnologia, possui aproximadamente 96.000 funcionários em todo o mundo e um valor de mercado que ultrapassa os 100 bilhões de dólares. A empresa é reconhecida por suas propostas de soluções sustentáveis e projetos voltados para a melhoria da qualidade de vida e eficiência em diversos setores, incluindo saúde, segurança e indústria.

Com uma forte presença no Brasil desde 1946, a 3M do Brasil se destaca como a quinta maior subsidiária da empresa em faturamento, refletindo sua relevância no mercado local. Além disso, a 3M investe continuamente em pesquisa e desenvolvimento, buscando inovações que atendam às necessidades dos consumidores e contribuam para um futuro mais sustentável. A empresa também se compromete com práticas de responsabilidade social, promovendo iniciativas que visam o bem-estar das comunidades onde está inserida.

3.3 INSTRUMENTOS E TECNOLOGIAS

A linguagem de programação Python (versão 3.12.3) foi utilizada devido a sua versatilidade e extensa cartela de bibliotecas, o que facilitou o desenvolvimento das aplicações complexas e orientadas aos dados presentes neste trabalho.

A biblioteca Numpy (versão 1.26.4), conhecida por sua eficiência na manipulação de arrays multidimensionais e por fornecer uma grande coleção de funções matemáticas. Foi essencial para o processamento numérico, elemento crucial para a implementação dos algoritmos de aprendizado de máquina.

A biblioteca Pandas (versão 2.2.3) foi utilizada para organizar, analisar e manipular os dados de forma eficiente. Suas estruturas de dados flexíveis, como DataFrames e Series, aliadas às ferramentas de leitura e tratamento de dados, simplificaram o processo de preparação dos dados utilizados no sistema.

A fim de construir, treinar e avaliar modelos de aprendizado de máquina, o estudo se beneficiou da biblioteca SciKit-Learn (versão 1.5.2), que oferecem uma variedade de algoritmos para classificação, regressão, clusterização e seleção de modelos. Sua interface consistente e documentação abrangente facilitaram a experimentação e otimização dos modelos.

Para o desenvolvimento de redes neurais, a biblioteca TensorFlow (versão 2.17.0), em conjunto com sua API de alto nível Keras (versão 3.6.0), forneceram um ambiente poderoso. A TensorFlow com sua capacidade de executar operações matemáticas complexas em GPU, acelerou o processo de treinamento dos modelos, enquanto a Keras simplificou a definição, o treinamento e a avaliação das arquiteturas de redes neurais.

A visualização concisa dos dados e dos resultados obtidos foi realizada por meio da biblioteca Matplotlib (versão 3.9.2). Suas ferramentas para a criação de gráficos e diagramas possibilitaram a análise e comunicação eficaz dos resultados do projeto, facilitando a interpretação dos padrões e tendências presentes nos dados.

A combinação dessas tecnologias forneceu um alicerce sólido e eficaz não só para o desenvolvimento, quanto para a validação do sistema proposto neste trabalho.

3.4 PROCEDIMENTO METODOLÓGICO

A aplicação metodológica do estudo aconteceu em dois momentos. No primeiro momento, foi realizada a coleta de dados no site Yahoo e em seguida, o tratamento e ajustes dos dados e a divisão dos dados entre dados treino e dados teste, para finalmente, construir a estrutura e treinamento do modelo. No segundo momento, foram utilizados os dados teste para efeito comparativo das previsões geradas, ou seja, o sistema plotou os dados teste juntamente com os dados previstos pelo modelo, para que assim fosse possível a realização da apuração do modelo, como descrito detalhadamente a seguir.

3.4.1 Importação e preparação dos dados

Inicialmente, foi realizado o download dos dados, e para este trabalho o site Yahoo Finance como a fonte dos dados. Como parte do pré-processamento de dados, os dados foram abertos em uma planilha no Excel, onde foram renomeadas as colunas, traduzindo do inglês

para o português. Após essa etapa, foram removidas todas as linhas que continham detalhes sobre o pagamento de dividendos pela empresa.

Neste ponto, obteve-se uma tabela que compreendeu todos os dados utilizados no desenvolvimento do trabalho. Porém foi necessário dividir estes dados em parte de treino e parte de testes. Desta forma, dividiu-se os dados de treino de 01/08/2013 até 30/06/2024, converteu-se este arquivo 'XLSX' em 'CSV' e foi nomeado 'TabelaTreino.csv' a este arquivo apresentado no Apêndice A. Com o arquivo teste pronto, foi repetido o mesmo processo para criar o arquivo 'TabelaTeste3M.csv', como apresentado no Apêndice B, porém neste arquivo os dados compreendidos são de 01/07/2024 até 30/09/2024.

Para iniciar o código, foram importadas as bibliotecas essenciais para a manipulação de dados, normalização, construção do modelo LSTM e visualização gráfica dos resultados, como visto no Algoritmo 1. Em seguida, realizou-se a leitura do arquivo 'TabelaTreino.csv', que contém os dados históricos que foram utilizados para o treinamento do modelo.

Algoritmo 1 – Importação de Bibliotecas

```
1: import numpy as np
2: import pandas as pd
3: from sklearn.preprocessing import MinMaxScaler
4: import matplotlib.pyplot as plt
5: from tensorflow.keras.models import Sequential
6: from tensorflow.keras.layers import Dense, LSTM, Dropout
7: from tensorflow.keras.callbacks import EarlyStopping
```

Fonte: Autoria própria (2025).

Ainda como parte do pré-processamento dos dados, as colunas de interesse foram convertidas para o formato numérico 'float', garantindo assim a correta manipulação dos dados. Em particular, a função `convert_to_float` foi implementada para tratar eventuais inconsistências na formatação dos valores, transformando-os de 'string' para 'float', ajustando as casas decimais e eliminando possíveis erros durante a execução do programa, como descrito no Algoritmo 2.

Algoritmo 2 – Função `convert_to_float`

```
1: def convert_to_float(value):
2:     if isinstance(value, str):
3:         try:
4:             return float(value.replace('.', '').replace(',', '.'))
5:         except ValueError:
6:             return np.nan
7:     return value
```

Fonte: Autoria própria (2025).

E para finalizar a etapa de pré-processamento dos dados, foi realizada uma normalização dos mesmos utilizando o uso da técnica de `MinMaxScaler`, que dimensiona os valores para um intervalo entre 0 e 1, favorecendo a convergência do modelo durante o treinamento. Como apresentado no Algoritmo 3.

Algoritmo 3 – Função MinMaxScaler

```
1: sc = MinMaxScaler(feature_range=(0, 1))
2: set_treino_scaled = sc.fit_transform(set_treino)
```

Fonte: Autoria própria (2025).

3.4.2 Criação da estrutura dos dados de entrada

Para modelar as séries temporais, foram criadas sequências de 60 dias de dados históricos, que serviram como entrada para o modelo LSTM. Cada sequência de 60 dias foi utilizada para prever o valor do sexagésimo primeiro dia. Essa abordagem visa capturar as relações temporais entre os dados passados e futuros, o que é essencial em modelos de previsão de séries temporais, conforme discutido por Browlee (2017). O Algoritmo 4 descreve de forma detalhada essa abordagem.

Algoritmo 4 – Criação da Estrutura do Modelo

```
1: X_treino = []
2: y_treino = []
3: for i in range(60, len(set_treino_scaled)):
4:     X_treino.append(set_treino_scaled[i-60:i, 0])
5:     y_treino.append(set_treino_scaled[i, 0])
6: X_treino, y_treino = np.array(X_treino), np.array(y_treino)
7: X_treino = np.reshape(X_treino, (X_treino.shape[0], X_treino.shape[1], 1))
```

Fonte: Autoria própria (2025).

3.4.3 Construção do modelo LSTM

O modelo foi construído utilizando a API Sequential da biblioteca Keras, composta por múltiplas camadas LSTM, intercaladas por camadas de Dropout para evitar que o modelo tenha um overfitting. O modelo conta com cinco camadas LSTM, cada uma delas com 50 neurônios, sendo que as quatro primeiras camadas retornam sequências, enquanto a última camada LSTM apenas retorna o valor final da previsão. Cada camada LSTM foi seguida por uma camada Dropout com taxa de 20%, que desliga aleatoriamente neurônios durante o treinamento, garantindo maior robustez do modelo, como descrito no Algoritmo 5 e ilustrado na Figura 5

3.4.4 Compilação e treinamento do modelo

O modelo foi compilado utilizando o otimizador adam e a função de perda mean_squared_error, comumente utilizada em problemas de regressão. Durante o treinamento, foi utilizado o método de *early stopping*, que interrompe o treinamento caso a função de perda não apresente melhora após um número X de épocas consecutivas, previamente definido, evitando o treinamento excessivo e a degradação do desempenho por *overfitting*. O modelo foi treinado por épocas variadas, com *batch size* também variado, para que fosse possível encontrar um

Algoritmo 5 – Construção do Modelo


```

1: regressor = Sequential()
2: regressor.add(LSTM(units=50, return_sequences=True, input_shape=(X_treino.shape[1], 1)))
3: regressor.add(Dropout(0.2))
4: regressor.add(LSTM(units=50, return_sequences=True))
5: regressor.add(Dropout(0.2))
6: regressor.add(LSTM(units=50, return_sequences=True))
7: regressor.add(Dropout(0.2))
8: regressor.add(LSTM(units=50, return_sequences=True))
9: regressor.add(Dropout(0.2))
10: regressor.add(LSTM(units=50))
11: regressor.add(Dropout(0.2))
12: regressor.add(Dense(units=1))

```

Fonte: Autoria própria (2025).

Figura 5 – Ilustração Modelo LSTM



Fonte: (Silva silas santiago lopes pereira,).

faixa de parâmetros que apresentem um melhor desempenho. O Algoritmo 6 descreve a compilação e treinamento do modelo.

Algoritmo 6 – Compilação e Treinamento do Modelo

```

1: regressor.compile(optimizer='adam', loss='mean_squared_error')
2: early_stopping = EarlyStopping(monitor='loss', patience=15)
3: regressor.fit(X_treino, y_treino, epochs=840, batch_size=28, callbacks=[early_stopping])

```

Fonte: Autoria própria (2025).

3.5 ANÁLISE DE DADOS

3.5.1 Teste e Avaliação do modelo

Após o treinamento, o modelo foi testado e avaliado utilizando os dados de teste contidos no arquivo TabelaTeste3M.csv. Os dados de teste foram previamente tratados de forma semelhante aos dados de treinamento, sendo normalizados e organizados em sequências de 60 dias para previsão dos valores futuros. A previsão realizada pelo modelo foi posteriormente revertida para a escala original utilizando o inverso da transformação aplicada pelo MinMaxScaler.

Para avaliar o desempenho do modelo, foi calculado o MAPE, que mede o erro percentual médio absoluto entre os valores reais e os valores previstos. O R^2 do modelo foi expressado de forma com que quanto mais próximo a 100%, mais eficaz o modelo é. No Algoritmo 7 estão descritos o teste do modelo e sua avaliação.

Algoritmo 7 – Testando Modelo e Avaliando as Métricas

```

1: dataset_teste = pd.read_csv("TabelaTeste3M.csv", sep=';')
2: valor_real = dataset_teste['Fechamento'].apply(convert_to_float).dropna().values
3: dataset_teste = dataset_teste.dropna()
4: inputs = dataset_treino['Fechamento'].values[-60:].tolist() + valor_real.tolist()
5: inputs = np.array(inputs).reshape(-1, 1)
6: inputs_scaled = sc.transform(inputs)
7: X_test = []
8: for i in range(60, len(inputs_scaled)):
9:     X_test.append(inputs_scaled[i-60:i, 0])
10: X_test = np.array(X_test)
11: X_test = np.reshape(X_test, (X_test.shape[0], X_test.shape[1], 1))
12: previsao_valor = regressor.predict(X_test)
13: previsao_valor = sc.inverse_transform(previsao_valor)
14: mape = np.mean(np.abs((valor_real - previsao_valor) / valor_real)) * 100
15: accuracy_percentage = 100 - mape
16: r_squared = r2_score(valor_real, previsao_valor)

```

Fonte: Autoria própria (2025).

3.5.2 Visualização dos resultados

Finalmente, os resultados foram apresentados em um gráfico, com a comparação entre os valores reais e os valores previstos. Utilizou-se a biblioteca matplotlib para gerar um gráfico com as duas curvas, uma representando os preços reais das ações e a outra representando as previsões realizadas pelo modelo. O gráfico inclui ainda o título com a acurácia obtida pelo modelo, além de legendas e eixos rotulados com quantidade de dias no eixo X e valor em Dólar das ações no eixo Y para facilitar a interpretação dos resultados. No Algoritmo 8 foi demonstrado o funcionamento da visualização dos resultados.

Algoritmo 8 – Visualizando os Resultados

```

1: plt.plot(valor_real, color='blue', label="Preço Real Ação 2024/2")
2: plt.plot(previsao_valor, color='green', label="Previsão Ação 2024/2")
3: plt.title(f"Predição valor Ação 3M : {mape:.2f}% - R-squared: {r_squared:.2f}")
4: plt.xlabel("Dias")
5: plt.ylabel("Preço Ação 3M")
6: plt.legend()
7: plt.show()

```

Fonte: Autoria própria (2025).

4 RESULTADOS E DISCUSSÃO

Este capítulo apresenta e analisa os resultados obtidos a partir da aplicação do modelo de rede neural LSTM para a previsão de preços da ação da empresa 3M. A performance do modelo foi avaliada em quatro cenários distintos, variando hiperparâmetros-chave como o tamanho do lote (*batch size*) e o número de épocas de treinamento. A avaliação quantitativa foi realizada por meio de duas métricas principais: o Coeficiente de Determinação (R^2), que indica a proporção da variância nos dados de preço que é explicada pelo modelo, e o MAPE, que mensura a acurácia da previsão em termos percentuais.

4.1 Análise de Desempenho dos Cenários

Para investigar o impacto dos hiperparâmetros no desempenho preditivo, foram conduzidos quatro experimentos. A Tabela 1 sumariza a configuração de cada cenário e os resultados obtidos.

Tabela 1 – Sumário das Variáveis e Métricas de Desempenho por Cenário.

Parâmetro	Cenário 1	Cenário 2	Cenário 3	Cenário 4
Batch Size	40	36	28	32
Épocas Executadas	135	115	106	95
Paciência (<i>Early Stopping</i>)	15	15	15	15
R-squared (R^2)	0.77	0.78	0.76	0.77
MAPE (%)	11.63%	11.35%	11.41%	11.40%


Fonte: Autor.

O modelo demonstrou um desempenho notavelmente estável e robusto em todas as configurações testadas. Os valores de R^2 variaram entre 0.76 e 0.78, indicando que o modelo foi capaz de explicar consistentemente mais de 76% da variabilidade dos preços reais da ação. O **Cenário 2** (Figura 6) apresentou o melhor desempenho geral, com o maior valor de R^2 (0.78) e o menor MAPE (11.35%), utilizando um *batch size* de 36 e 115 épocas de treinamento.

Uma análise visual dos gráficos de predição (Figuras 6, 7, 8 e 9) revela a capacidade do modelo em acompanhar a tendência geral dos preços. Observa-se que a linha de previsão (em verde) segue de perto a linha de preço real (em azul), capturando tanto os períodos de menor volatilidade quanto as flutuações mais agudas.


Um ponto de destaque é a performance do modelo diante da acentuada queda de preços ocorrida por volta do dia 45 do período de teste. Em todos os cenários, a rede LSTM foi capaz de prever este movimento de baixa abrupta, um desafio notório para modelos de séries temporais financeiras devido à natureza muitas vezes imprevisível de tais eventos. Embora a previsão não espelhe perfeitamente a magnitude exata da queda, ela captura a direção e a mudança de patamar do preço, o que representa um resultado significativo.

Figura 6 – Predição do Valor da Ação 3M - Cenário 2 (R^2 : 0.78, MAPE: 11.35%)




Fonte: Autor.

Figura 7 – Predição do Valor da Ação 3M - Cenário 1 (R^2 : 0.77, MAPE: 11.63%)




Fonte: Autor.

Figura 8 – Predição do Valor da Ação 3M - Cenário 3 (R^2 : 0.76, MAPE: 11.41%)



Fonte: Autor.

Figura 9 – Predição do Valor da Ação 3M - Cenário 4 (R^2 : 0.77, MAPE: 11.40%)



Fonte: Autor.

4.2 Discussão dos Resultados

A avaliação do desempenho de um modelo de previsão de séries temporais financeiras deve ser contextualizada. O mercado de ações é um sistema complexo, influenciado por vários fatores, muitos dos quais são não-quantificáveis, como o sentimento do mercado, eventos geopolíticos súbitos e notícias, o que o torna notoriamente difícil de prever com alta precisão. Nesse contexto, os resultados obtidos neste trabalho são promissores e informativos.

Uma análise mais aprofundada das métricas revela a robustez do modelo. O Coeficiente de Determinação (R^2), situando-se consistentemente entre 0.76 e 0.78, é um indicador robusto da qualidade do ajuste. Isso significa que o modelo foi capaz de explicar entre 76% e 78% da variabilidade observada nos preços da ação da 3M durante o período de teste. A porção restante da variância (aproximadamente 22-24%) pode ser atribuída ao "ruído" do mercado e a fatores externos que não foram incluídos no modelo, o que é uma limitação inerente e esperada para modelos que se baseiam unicamente em dados históricos de preço.

Por sua vez, o MAPE, que variou minimamente entre 11.35% e 11.63%, oferece uma perspectiva prática da acurácia. Ele indica que o erro médio da previsão foi de aproximadamente 11.5% em relação ao valor real da ação. Embora a busca por MAPEs de um dígito seja um objetivo comum, o valor obtido é competitivo, especialmente considerando a ausência de variáveis externas (como notícias do mercado, volume de negociação ou indicadores macroeconômicos) que poderiam refinar as previsões. A estabilidade do MAPE e do R^2 entre os quatro cenários, apesar das variações nos parâmetros de *batch size* e épocas, também sugere que a arquitetura LSTM escolhida é estável e não sofre de *overfitting* de forma crítica a uma configuração específica.

Um dos achados mais significativos, visível em todas as quatro figuras, é a capacidade do modelo de antecipar a direção da queda abrupta de preços ocorrida por volta do dia 45. Enquanto a previsão não espelha perfeitamente a magnitude do colapso, a captura correta da tendência descendente acentuada demonstra que o modelo aprendeu padrões que vão além de uma simples média móvel, sendo sensível a mudanças na dinâmica dos preços. Este é um ponto importante, pois a utilidade de um modelo de previsão é não apenas em acertar os preços em períodos de estabilidade, mas oferecer tendências corretas durante eventos de alta volatilidade.

Contextualizando os dados obtidos com outros trabalhos, temos por exemplo, Fischer e Krauss (2018) onde demonstraram que LSTMs superam modelos de ML tradicionais, como *Random Forest*, para a previsão da direção de preços no mercado de S&P 500, embora não foquem em valores de R^2 . Já Selvin *et al.* (2017), em um estudo de previsão de ações listadas na NSE (*National Stock Exchange of India*), obtiveram erros de previsão (RMSE) baixos, validando a eficácia das LSTMs.

Nossos resultados, com R^2 consistentemente acima de 0.75, estão alinhados com a expectativa para um modelo robusto de previsões de ativos individuais, os quais são mais voláteis e ruidosos que índices de mercado.

Em síntese, os experimentos demonstram que a arquitetura LSTM configurada neste trabalho é uma ferramenta promissora e eficaz para a modelagem de séries temporais de preços de ações. A consistência dos resultados em diferentes cenários de hiperparâmetros reforça a validade do modelo. Os valores de R^2 e MAPE, aliados à capacidade de prever movimentos bruscos, sugerem um potencial prático para a aplicação da rede como ferramenta de apoio à análise de investimentos.

5 CONSIDERAÇÕES FINAIS

Este trabalho de conclusão de curso teve como objetivo investigar o uso de redes neurais do tipo LSTM na previsão de séries temporais financeiras, utilizando os preços de fechamento das ações da empresa 3M como estudo de caso. Ao longo da pesquisa, foi possível compreender o desempenho desse tipo de modelo e avaliar seu potencial como ferramenta de análise no contexto do mercado financeiro.

De maneira geral, os resultados obtidos mostraram que a rede LSTM é uma solução promissora e eficaz para a tarefa de previsão de preços. O modelo apresentou desempenho consistente mesmo com variações nos hiperparâmetros, atingindo um R^2 de até 0,78 e um MAPE mínimo de 11,35%. Um dos aspectos mais relevantes foi a capacidade do modelo de antecipar movimentos mais bruscos do mercado, como a queda acentuada de preços no período de teste — algo que modelos estatísticos tradicionais apresentam dificuldade em capturar. Isso reforça o valor das LSTM na modelagem de padrões complexos e não lineares presentes nos dados financeiros.

Apesar dos resultados positivos, é importante destacar algumas limitações que este estudo enfrentou e que podem servir como ponto de partida para futuras investigações, como:

- **Foco exclusivo no preço:** A previsão considerou apenas os dados históricos dos preços das ações, sem levar em conta outras variáveis que também influenciam o mercado, como volume de negociações, indicadores econômicos, índices de mercado ou mesmo o sentimento extraído de notícias. A ausência desses fatores limita a abrangência do modelo.
- **Validação restrita a um único ativo:** O modelo foi treinado e testado apenas com dados da ação da 3M, em um período específico. Assim, não é possível afirmar com segurança que ele teria o mesmo desempenho em outras ações, de setores diferentes ou com níveis distintos de volatilidade.
- **Exploração limitada de parâmetros:** Foram testadas quatro combinações de ajustes no modelo, que já apresentaram bons resultados. No entanto, é provável que existam configurações ainda mais eficientes que não foram exploradas. Uma abordagem futura mais sistemática, como o uso do *Grid Search*, poderia otimizar ainda mais o desempenho.

Diante dessas limitações, algumas direções futuras se mostram promissoras:

1. **Desenvolvimento de Modelos Multivariados:** Incluir variáveis externas pode melhorar significativamente a precisão das previsões. Dados como fundamentos da empresa, indicadores técnicos e até informações extraídas de notícias financeiras (usando técnicas de Processamento de Linguagem Natural) podem enriquecer o modelo.

2. **Explorar Arquiteturas Híbridas:** Combinar LSTM com outras abordagens de deep learning, como CNN-LSTM (que capta padrões locais) ou modelos de volatilidade como o GARCH, pode oferecer uma visão mais completa do comportamento dos preços.
3. **Testes de Generalização e Robustez:** Aplicar a metodologia desenvolvida a diferentes ações e cenários de mercado — como períodos de alta, baixa e lateralização — pode validar melhor a eficácia e a adaptabilidade do modelo.

Em suma, este trabalho demonstrou que a rede LSTM é uma alternativa viável e de alto desempenho para a previsão de preços de ações. Mais do que isso, oferece uma base sólida para estudos futuros que desejem explorar estratégias mais complexas, buscando não apenas aumentar a precisão das previsões, mas também contribuir para o desenvolvimento de sistemas de apoio à decisão mais inteligentes e adaptativos no ambiente financeiro.

REFERÊNCIAS

- AVELLA, A. Next-generation portfolio optimization: Integrating classical methods, machine learning, stochastic models and entropy analysis. **SSRN Electronic Journal**, „, 06 2024.
- BALAKRISHNA, C.; SRINIVASULU, S. Drug suggestion mechanism in medical emergencies using machine learning. **International Journal of Science and Research Archive**, v. 13,, p. 901–906, 09 2024.
- BREALEY, R. *et al.* **Principles of Corporate Finance**. McGraw-Hill Education, 2012. ISBN 9781259004650. Disponível em: <https://books.google.com.br/books?id=XMgJAgAAQBAJ>.
- CARRIJO, A. Análise de preços de ações bancárias no brasil: uma abordagem com redes neurais LSTM, . Uberlândia, MG,, 2023. Disponível em: <https://repositorio.ufu.br/handle/123456789/38901>.
- CORTES, C.; VAPNIK, V. Support-vector networks. **Machine Learning**, v. 20, n. 3, p. 273–297, Sep 1995. ISSN 1573-0565. Disponível em: <https://doi.org/10.1007/BF00994018>.
- FAMA, E. F. Efficient capital markets: A review of theory and empirical work. **The Journal of Finance**, [American Finance Association, Wiley] v. 25, n. 2, p. 383–417, 1970. ISSN 00221082, 15406261. Disponível em: <http://www.jstor.org/stable/2325486>.
- FAMA, E. F.; FRENCH, K. R. A five-factor asset pricing model. **Journal of Financial Economics**, v. 116, n. 1, p. 1–22, 2015. ISSN 0304-405X. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0304405X14002323>.
- FAMA, E. F.; FRENCH, K. R. The cross-section of expected stock returns. **The Journal of Finance**, [American Finance Association, Wiley] v. 47, n. 2, p. 427–465, 1992. ISSN 00221082, 15406261. Disponível em: <http://www.jstor.org/stable/2329112>.
- FANTIN, C. O. **Projeção de preços de ações com redes neurais artificiais multi layer perceptron e long short term memory**. 2023. Dissertação (Dissertação (Mestrado)) — Universidade Presbiteriana Mackenzie São Paulo 2023.
- FISCHER, T.; KRAUSS, C. Deep learning with long short-term memory networks for financial market predictions. **European Journal of Operational Research**, v. 270, n. 2, p. 654–669, 2018. ISSN 0377-2217. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0377221717310652>.
- GAO, J. *et al.* Embracing market dynamics in the post-covid era: A data-driven analysis of investor sentiment and behavioral characteristics in stock index futures returns. **Omega**, v. 131,, p. 103193, 2025. ISSN 0305-0483. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0305048324001580>.
- GRAHAM, B.; DODD, D. **Security Analysis: Sixth Edition, Foreword by Warren Buffett**. McGraw Hill LLC, 2008. (Axis 360). ISBN 9780071642934. Disponível em: <https://books.google.com.br/books?id=-SVwCBG5ZiwC>.
- GRANGER, C.; NEWBOLD, P. **Forecasting Economic Time Series**. Academic Press, 1977. (Economic theory and mathematical economics). ISBN 9780122951503. Disponível em: <https://books.google.com.br/books?id=IVoEAQAIAAJ>.
- HAEFNER, N. *et al.* Artificial intelligence and innovation management: A review, framework, and research agenda. **Technological Forecasting and Social Change**, v. 162,, p. 120392,

2021. ISSN 0040-1625. Disponível em: <https://www.sciencedirect.com/science/article/pii/S004016252031218X>.

HALEVY, A.; NORVIG, P.; PEREIRA, F. The unreasonable effectiveness of data. **IEEE Intelligent Systems**, v. 24, n. 2, p. 8–12, 2009.

HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. **Neural computation**, v. 9, p. 1735–80, 12 1997.

HUA, Y. *et al.* Deep learning with long short-term memory for time series prediction. **IEEE Communications Magazine**, v. 57, n. 6, p. 114–119, 2019.

HULL, J. **Options, Futures, and Other Derivatives, eBook, Global Edition**. Pearson Education, 2017. ISBN 9781292212920. Disponível em: <https://books.google.com.br/books?id=2iopDwAAQBAJ>.

JANSEN, S. **Machine Learning for Algorithmic Trading: Predictive models to extract signals from market and alternative data for systematic trading strategies with Python**. Packt Publishing, 2020. ISBN 9781839216787. Disponível em: <https://books.google.com.br/books?id=4f30DwAAQBAJ>.

KHAN, M. Corporate governance, esg, and stock returns around the world. **Financial Analysts Journal**, v. 75, p. 1, 10 2019.

KIM, H. Y.; WON, C. H. Forecasting the volatility of stock price index: A hybrid model integrating lstm with multiple garch-type models. **Expert Syst. Appl.**, v. 103, p. 25–37, 2018. Disponível em: <https://api.semanticscholar.org/CorpusID:19236706>.

KRIZHEVSKY, A.; SUTSKEVER, I.; HINTON, G. E. Imagenet classification with deep convolutional neural networks. *In*: PEREIRA, F. *et al.* (Ed.). **ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS**. 25., 2012. **Anais [...]** Curran Associates, Inc., 2012. Disponível em: https://proceedings.neurips.cc/paper_files/paper/2012/file/c399862d3b9d6b76c8436e924a68c45b-Paper.pdf.

KUMAR, S. *et al.* Journal of behavioral and experimental finance: A bibliometric overview. **Journal of Behavioral and Experimental Finance**, v. 34, p. 100652, 2022. ISSN 2214-6350. Disponível em: <https://www.sciencedirect.com/science/article/pii/S2214635022000181>.

LECUN, Y. *et al.* Gradient-based learning applied to document recognition. **Proceedings of the IEEE**, v. 86, n. 11, p. 2278–2324, 1998.

LINDEMANN, B. *et al.* A survey on long short-term memory networks for time series prediction. **Procedia CIRP**, v. 99, p. 650–655, 2021. ISSN 2212-8271. 14th CIRP Conference on Intelligent Computation in Manufacturing Engineering, 15-17 July 2020. Disponível em: <https://www.sciencedirect.com/science/article/pii/S2212827121003796>.

MCCARTHY, J. *et al.* A proposal for the dartmouth summer research project on artificial intelligence. **AI Magazine**, v. 27, p. 12 2006.

MEHTAB, S.; SEN, J.; DUTTA, A. Stock price prediction using machine learning and lstm-based deep learning models, . Springer Singapore Singapore, p. 88–106, 2021.

MINSKY, M.; PAPERT, S. A. **Perceptrons: An Introduction to Computational Geometry**. The MIT Press, 2017. ISBN 9780262343930. Disponível em: <https://doi.org/10.7551/mitpress/11301.001.0001>.

MISHKIN, F.; EAKINS, S. **Financial Markets and Institutions, Global Edition**. Pearson Education, 2018. ISBN 9781292215037. Disponível em: <https://books.google.com.br/books?id=PPJFDwAAQBAJ>.

- MOGHAR, A.; HAMICHE, M. Stock market prediction using lstm recurrent neural network. **Procedia Computer Science**, v. 170,, p. 1168–1173, 2020. ISSN 1877-0509. The 11th International Conference on Ambient Systems, Networks and Technologies (ANT) / The 3rd International Conference on Emerging Data and Industry 4.0 (EDI40) / Affiliated Workshops. Disponível em: <https://www.sciencedirect.com/science/article/pii/S1877050920304865>.
- MUHAMMAD, D. *et al.* An explainable deep learning approach for stock market trend prediction. **Heliyon**, v. 10, n. 21, p. e40095, 2024. ISSN 2405-8440. Disponível em: <https://www.sciencedirect.com/science/article/pii/S2405844024161269>.
- MURPHY, K. J. Executive compensation. *In*: . Elsevier, 1999. cap. Chapter 38, p. 2485–2563. (Handbook of Labor Economics, v. 3). Disponível em: <https://www.sciencedirect.com/science/article/pii/S1573446399300249>.
- NASCIMENTO, O.; SANTOS, F.; FERREIRA, K. Previsão de preços de ações utilizando inteligência artificial. *In*: ANAIS DO I BRAZILIAN WORKSHOP ON ARTIFICIAL INTELLIGENCE IN FINANCE. 2022, Porto Alegre, RS, Brasil. **Anais [...]** Porto Alegre, RS, Brasil: SBC, 2022. p. 37–47. ISSN 0000-0000. Disponível em: <https://sol.sbc.org.br/index.php/bwaif/article/view/20485>.
- POTTER, K. Machine learning in financial fraud detection. **Financial Management**, ,, 10 2024.
- PRICOPE, T.-V. Deep reinforcement learning in quantitative algorithmic trading: A review, ,,. 05 2021.
- RIZELIOĞLU, M. An extensive bibliometric analysis of pavement deterioration detection using sensors and machine learning: Trends, innovations, and future directions. **Alexandria Engineering Journal**, v. 112,, p. 349–366, 2025. ISSN 1110-0168. Disponível em: <https://www.sciencedirect.com/science/article/pii/S1110016824011219>.
- ROSENBLATT, F. The perceptron: A probabilistic model for information storage and organization (1958). *In*: **Ideas That Created the Future: Classic Papers of Computer Science**. The MIT Press 2021. ISBN 9780262363174. Disponível em: <https://doi.org/10.7551/mitpress/12274.003.0020>.
- ROSS, S.; WESTERFIELD, R.; JAFFE, J. **Corporate Finance**. McGraw-Hill/Irwin, 2005. (Irwin series in finance). ISBN 9780072971231. Disponível em: <https://books.google.com.br/books?id=1DexAAAAIAAJ>.
- RUMELHART, D. E.; HINTON, G. E.; WILLIAMS, R. J. Learning representations by back-propagating errors. **Nature**, v. 323, n. 6088, p. 533–536, Oct 1986. ISSN 1476-4687. Disponível em: <https://doi.org/10.1038/323533a0>.
- RUNDO, F. *et al.* Machine learning for quantitative finance applications: A survey. **Applied Sciences**, v. 9,, p. 1–20, 12 2019.
- SAHU, S.; MOKHADE, A.; BOKDE, N. An overview of machine learning, deep learning, and reinforcement learning-based techniques in quantitative finance: Recent progress and challenges. **Applied Sciences**, v. 13,, p. 1956, 02 2023.
- SAMUEL, A. L. Some studies in machine learning using the game of checkers. **IBM Journal of Research and Development**, v. 3, n. 3, p. 210–229, 1959.
- SELVIN, S. *et al.* Stock price prediction using lstm, rnn and cnn-sliding window model, ,,. p. 1643–1647, 09 2017.
- SHANNON, C. E. A mathematical theory of communication. **The Bell System Technical Journal**, v. 27,, p. 379–423, 1948. Disponível em: <https://people.math.harvard.edu/~ctm/home/>

text/others/shannon/entropy/entropy.pdf#:~:text=x%20giving%20a%20maximum%20entropy%20subject%20to%20the.

SHEN, G. *et al.* Deep learning with gated recurrent unit networks for financial sequence predictions. **Procedia Computer Science**, v. 131,, p. 895–903, 2018. ISSN 1877-0509. Recent Advancement in Information and Communication Technology:. Disponível em: <https://www.sciencedirect.com/science/article/pii/S1877050918306781>.

SHERSTINSKY, A. Fundamentals of recurrent neural network (RNN) and long short-term memory (LSTM) network. **CoRR**, abs/1808.03314,,, 2018. Disponível em: <http://arxiv.org/abs/1808.03314>.

SILVA SILAS SANTIAGO LOPES PEREIRA, M. W. d. L. M. Alexandre Pereira da. **AVALIAÇÃO DE DESEMPENHO DE REDES NEURAIS RECORRENTES DO TIPO LSTM PARA DECISÃO DE INVESTIMENTO DE CURTO PRAZO NO MERCADO DE AÇÕES**. [S.l.]: , . <https://gestaoaracati.ifce.edu.br/attachments/download/2532/tcc.pdf>. [Accessed 13-06-2025].

SONG, J. *et al.* Lstm-based deep learning model for financial market stock price prediction, ,, p. 43–50, 04 2024.

TURING, A. 433computing machinery and intelligence (1950). *In: The Essential Turing*. Oxford University Press 2004. ISBN 9780198250791. Disponível em: <https://doi.org/10.1093/oso/9780198250791.003.0017>.

VIJH, M. *et al.* Stock closing price prediction using machine learning techniques. **Procedia Computer Science**, v. 167,, p. 599–606, 2020. ISSN 1877-0509. International Conference on Computational Intelligence and Data Science. Disponível em: <https://www.sciencedirect.com/science/article/pii/S1877050920307924>.

ZAHEER, S. *et al.* A multi parameter forecasting for stock time series data using lstm and deep learning model. **Mathematics**, v. 11,, p. 590, 01 2023.

ZHENG, H. *et al.* Predicting financial enterprise stocks and economic data trends using machine learning time series analysis. **Applied and Computational Engineering**, v. 87,, p. 26–32, 07 2024.

ZULQARNAIN *et al.* Predicting financial prices of stock market using recurrent convolutional neural networks. **International Journal of Intelligent Systems and Applications**, v. 12,,, 12 2020.

APÊNDICES

APÊNDICE A – Tabela Treino

Figura 10 – Tabela Treino

Data	Abertura	Max	Min	Fechamen	Fechamen	Volume
Jun 28, 2024	103.01	103.97	101.66	102.19	101.64	6,196,500
Jun 27, 2024	101.96	104.04	101.64	103.17	102.62	4,338,300
Jun 26, 2024	101.62	101.80	100.57	101.45	100.91	2,356,100
Jun 25, 2024	102.88	103.18	101.29	102.05	101.50	5,164,200
Jun 24, 2024	102.18	103.50	101.68	102.99	102.44	2,948,000
Jun 21, 2024	101.93	102.44	100.95	102.39	101.84	7,866,200
Jun 20, 2024	100.26	102.34	100.19	101.66	101.11	3,476,600
Jun 18, 2024	100.07	101.47	100.06	100.77	100.23	3,446,200
Jun 17, 2024	99.98	101.44	99.92	100.53	99.99	3,490,000
Jun 14, 2024	100.50	101.42	99.31	100.90	100.36	2,685,000
Jun 13, 2024	102.02	102.80	100.74	101.54	101.00	5,034,700
Jun 12, 2024	102.62	103.68	100.76	101.21	100.67	3,704,600
Jun 11, 2024	100.10	101.47	99.23	101.32	100.78	2,831,500
Jun 10, 2024	100.43	101.84	100.28	100.66	100.12	3,507,600
Jun 7, 2024	99.51	101.96	98.40	100.86	100.32	5,636,700
Jun 6, 2024	98.80	99.55	98.16	98.22	97.69	2,510,000
Jun 5, 2024	98.82	99.65	97.87	99.06	98.53	3,115,400
Jun 4, 2024	99.00	99.40	97.68	98.61	98.08	4,988,100
Jun 3, 2024	100.37	100.79	98.97	99.76	99.23	4,508,100
May 31, 2024	98.06	100.25	97.42	100.14	99.60	21,754,400
May 30, 2024	97.69	98.23	96.89	98.20	97.67	4,520,300
May 29, 2024	97.80	97.90	96.76	97.56	97.04	4,826,600
May 28, 2024	99.56	100.11	97.82	98.68	98.15	4,360,900
May 24, 2024	99.81	100.52	99.34	99.67	99.14	2,602,000
May 23, 2024	100.42	100.52	98.91	99.51	98.98	3,845,500
May 22, 2024	102.64	103.11	100.95	101.49	100.25	3,807,800
May 21, 2024	104.89	105.04	102.65	103.14	101.88	4,603,000

Fonte: Autor.

APÊNDICE B – Tabela Teste

Figura 11 – Tabela Teste

Data	Abertura	Max	Min	Fechamen	Fechamen	Volume
Sep 30, 20	137.83	137.95	135.23	136.70	136.70	3,814,000
Sep 27, 20	139.00	139.29	137.05	137.30	137.30	2,956,100
Sep 26, 20	137.56	140.72	137.55	139.44	139.44	4,111,100
Sep 25, 20	137.23	137.89	136.04	136.60	136.60	3,579,900
Sep 24, 20	136.47	137.94	136.35	137.22	137.22	3,145,300
Sep 23, 20	134.70	136.09	134.69	135.64	135.64	2,638,400
Sep 20, 20	133.01	134.95	132.77	134.77	134.77	11,579,600
Sep 19, 20	134.40	135.32	133.32	133.84	133.84	2,691,500
Sep 18, 20	133.26	134.28	131.76	133.36	133.36	2,960,900
Sep 17, 20	134.09	134.43	132.31	133.57	133.57	3,969,000
Sep 16, 20	133.98	135.28	133.83	134.61	134.61	3,069,300
Sep 13, 20	131.88	133.37	131.35	133.18	133.18	2,670,100
Sep 12, 20	130.30	132.72	130.10	132.03	132.03	3,978,800
Sep 11, 20	129.50	130.38	127.12	130.23	130.23	3,283,800
Sep 10, 20	128.85	130.16	128.46	130.09	130.09	2,732,500
Sep 9, 202	129.39	130.98	128.19	128.46	128.46	3,616,300
Sep 6, 202	130.50	132.10	128.02	128.60	128.60	3,562,200
Sep 5, 202	131.92	132.95	130.70	131.40	131.40	2,726,000
Sep 4, 202	131.19	132.86	130.85	132.15	132.15	3,300,700
Sep 3, 202	133.01	133.78	130.21	130.85	130.85	4,024,100
Aug 30, 20	133.07	134.99	132.61	134.69	134.69	6,092,800
Aug 29, 20	131.65	133.18	131.34	132.91	132.91	2,992,600
Aug 28, 20	131.40	132.62	131.15	131.61	131.61	3,274,000
Aug 27, 20	131.32	132.62	130.95	131.40	131.40	2,878,500
Aug 26, 20	129.60	131.92	129.60	131.85	131.85	3,915,800
Aug 23, 20	129.23	130.65	128.85	130.55	129.85	2,618,800
Aug 22, 20	129.10	129.75	128.30	128.60	127.91	2,300,400
Aug 21, 20	127.84	129.99	127.66	129.23	128.54	3,664,600

Fonte: Autor.